

HACKATHON 7 · CASO 3

Planificador logístico multi-agente

CrewAI + Groq (gpt-oss-20b / gpt-oss-120b)

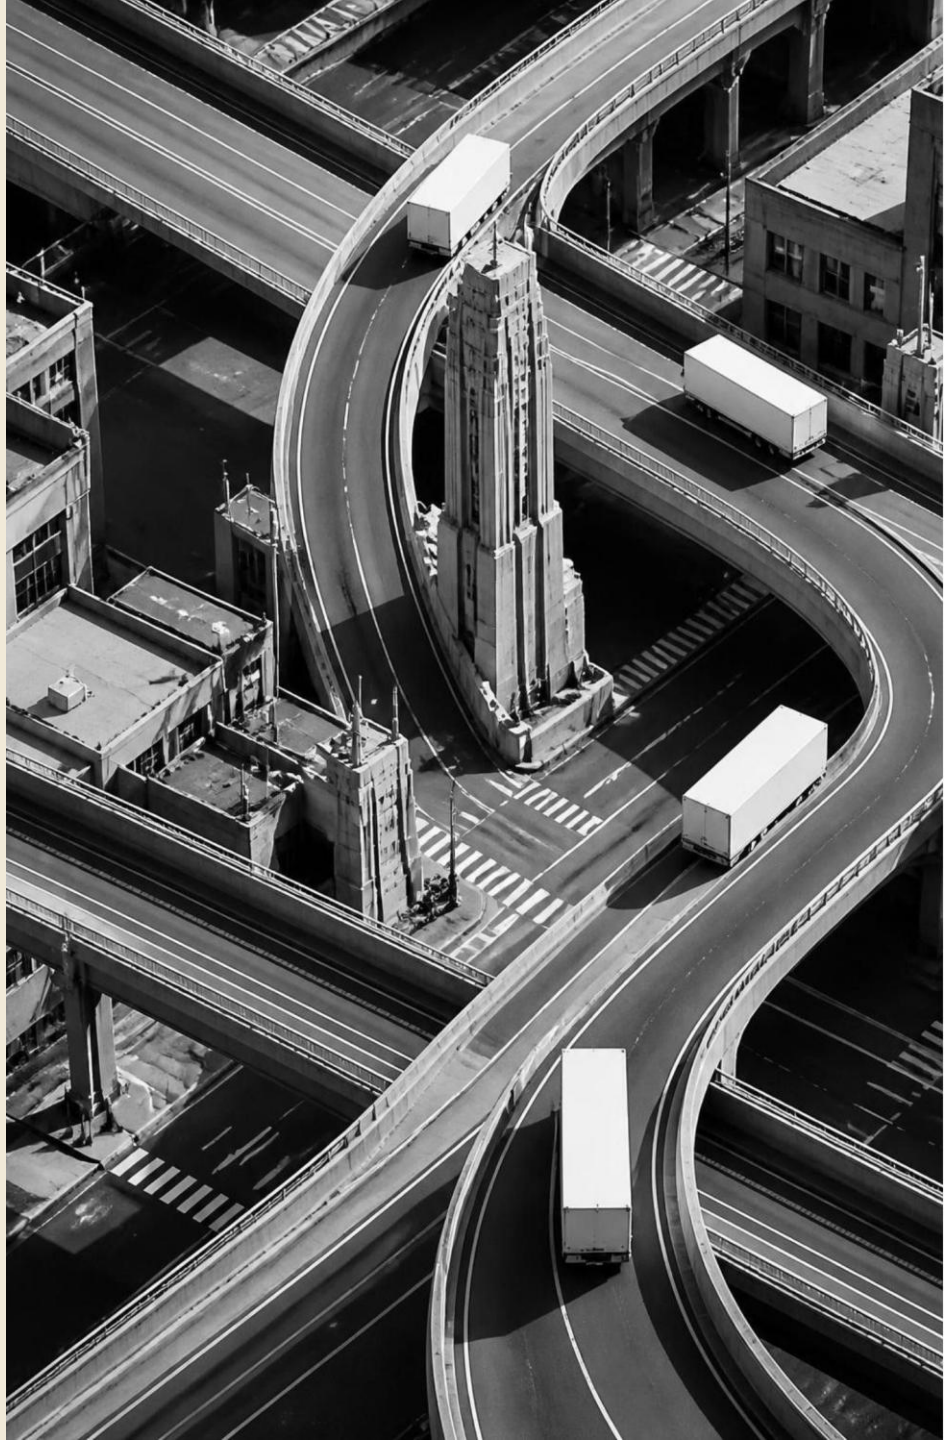
Ekypooh — Luis Anthony Romero Padilla · Andrés Martin Benjamín Torres Ramos

Octubre 2026

CONTEXTO Y RETO OPERATIVO

El problema: repartir bien, cada mañana

- Distribuidora con almacén en Ate: 15–20 pedidos diarios en 7 distritos de Lima y 3 vehículos
- Decisión que apoyamos: qué vehículo atiende qué pedidos, en qué orden y si conviene recargar
- Restricciones: capacidad, ventanas horarias, hora punta (x1.4) y regreso antes de las 19:00
- Usuario: jefe de despacho, antes de la salida de las 08:00 y ante imprevistos
- Impacto: pasar de ~45 min de planificación 'a ojo' a minutos, con alternativas comparables y trazables
- Criterios: factibilidad → cero pedidos de alta prioridad tarde → objetivo del día → menor riesgo



CONFIGURACIÓN DEL SISTEMA

Prompt inicial: 4 entradas y 2 escenarios

4 ENTRADAS AL SISTEMA

Entrada	Contenido
pedidos	id ; distrito ; kg ; ventana ; prioridad
flota	vehículos, capacidad, S/ por km y por hora, disponibilidad
restricciones	reglas del turno + imprevistos del día
objetivo	lo que prioriza la gerencia hoy (costo o servicio)

2 ESCENARIOS DE EVALUACIÓN

Variable	Escenario A	Escenario B
Pedidos	15 (2 240 kg)	17 (2 480 kg) — 2 urgentes
Flota	V1, V2, V3 (2 600 kg)	V2 en mantenimiento (1 600 kg)
Objetivo	Mínimo costo	Nivel de servicio
Reto	Ventanas + hora punta	Requiere recarga

- Datos sintéticos pero realistas (matriz de tiempos entre distritos), definidos en el notebook para reproducir la ejecución
- Validación determinista antes de llamar al LLM: si los datos están mal, el flujo se detiene

ARQUITECTURA DE AGENTES

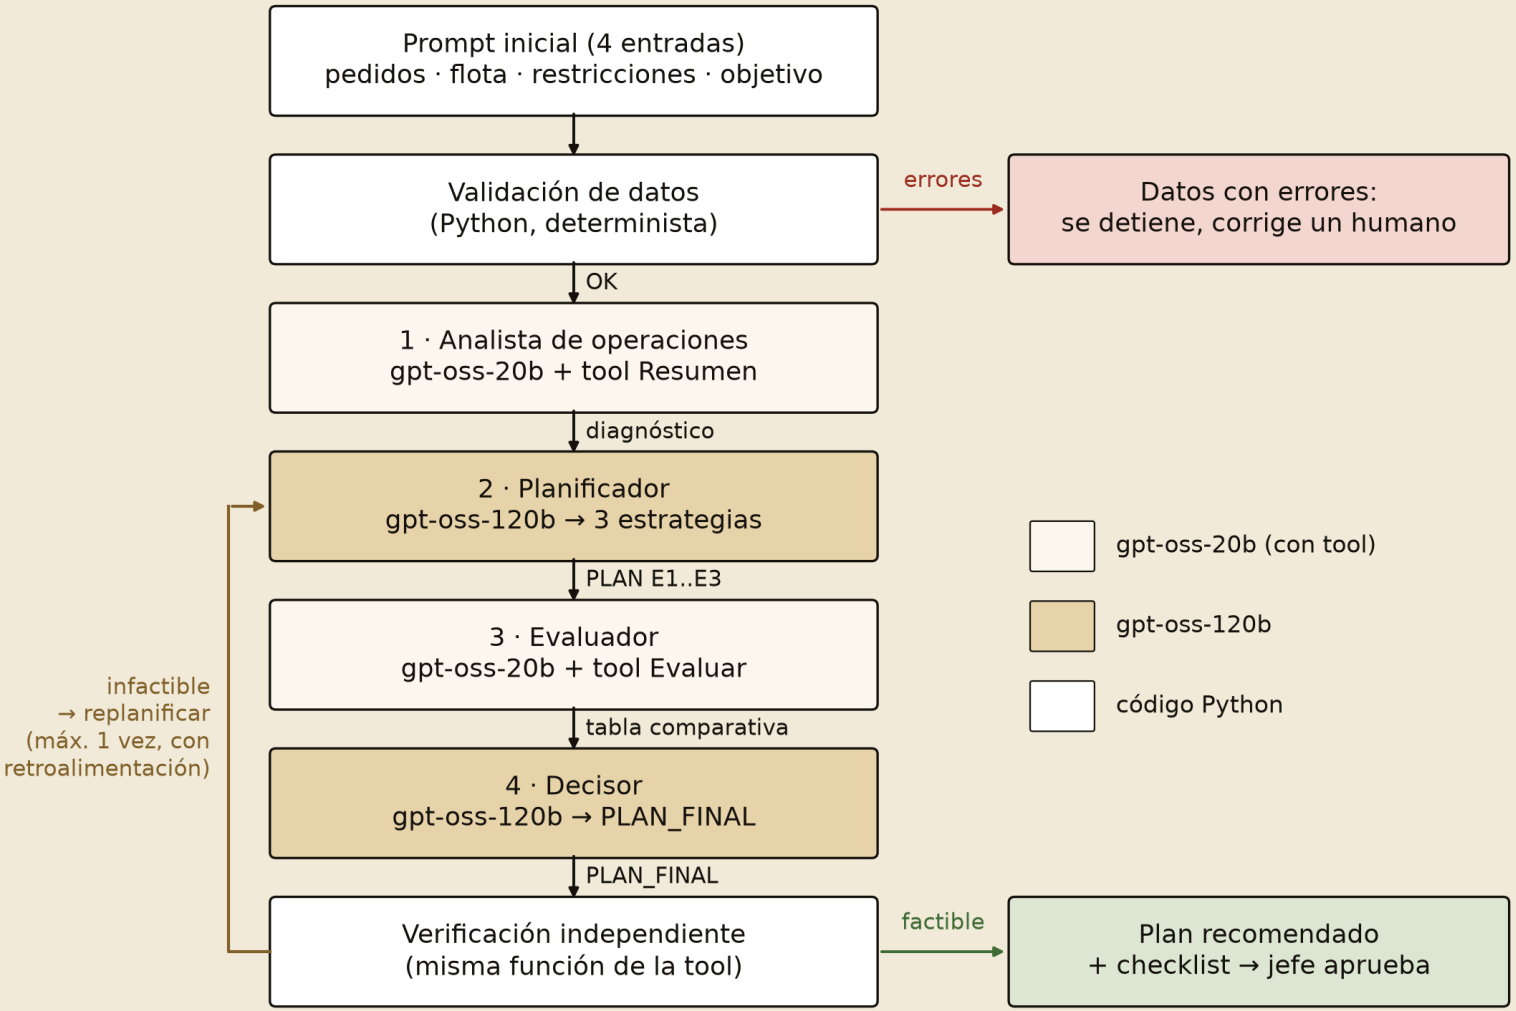
Diseño: 4 agentes con roles diferenciados

Agente	Recibe	Produce	Tool	Modelo
Analista de operaciones	4 entradas	Diagnóstico por zona, capacidad, críticos	Resumen por zona	gpt-oss-20b
Planificador	Diagnóstico + matriz	3 estrategias distintas (PLAN E1..E3)	—	gpt-oss-120b
Evaluador	Estrategias	Tabla costo/km/tardanzas/riesgo	Evaluar estrategias	gpt-oss-20b
Decisor	Estrategias + evaluación	Decisión, riesgos, checklist, PLAN_FINAL	—	gpt-oss-120b

- ¿Por qué 4? Con 3, quien propone se evaluaría a sí mismo; con 5, más tokens sin más calidad (la validación la hace código)
- Instrucciones propias del caso: reglas contra la invención de datos y formato estricto que el siguiente agente puede procesar
- 20b en las tareas con tool y 120b en las de razonamiento; alternarlos reparte el límite de tokens por minuto de Groq

FLUJO DE EJECUCIÓN Y CONTROL

Orquestación: secuencial + replanificación condicional



- **Process.sequential** con context entre tareas
- Si el PLAN_FINAL es infactible → se replanifica 1 vez con retroalimentación (sin repetir el analista)
- El Decisor integra; el humano aprueba

> *El Decisor integra la respuesta final. Las cifras salen siempre de las tools, no del LLM.*



DIVISIÓN COGNITIVA Y TÉCNICA

El LLM razona y el código calcula

- **Tools deterministas (@tool de CrewAI):**
  - Resumen de operación por zona → kg, ventanas, salidas mínimas, pedidos críticos
  - Evaluar estrategias → simulación minuto a minuto: hora punta, esperas, capacidad por viaje, fin de turno
- **Verificación independiente:** el PLAN_FINAL se vuelve a simular fuera del LLM
- **Gestión de API keys y de cuota en Groq:**
  - Key en .env (nunca en el notebook) + getpass + key de respaldo de otro integrante
  - Antes de la demo leemos las cabeceras x-ratelimit-*; límite de 8K tokens/min por modelo
  - Pausas entre agentes, reasoning_effort bajo, salidas de tools recortadas, reintentos ante 429

VALIDACIÓN EXPERIMENTAL

Demo en vivo (Groq)

- Celda 2.2: ping a Groq + cuota restante
- Escenario A → salida de cada agente (analista, planificador, evaluador, decisor)
- Verificación independiente del plan elegido
- Escenario B → el sistema recurre a recargas porque falta un vehículo
- Datos corruptos → la compuerta detiene el flujo sin gastar tokens
- Respaldo si falla la conexión: salidas guardadas en evidencias/A_*.md y B_*.md



RESULTADOS COMPARATIVOS

Decisión recomendada

Criterio	Escenario A (costo)	Escenario B (servicio)
Estrategia elegida	E2 – Por ventanas	E2 – Por ventanas + 2 recargas (2.º intento)
Verificación	FACTIBLE · S/ 776.07 · 236 km	FACTIBLE · S/ 838.03 · 279 km
Fuera de ventana	0	2 normales (P09, P10) · 0 de alta prioridad
Brecha frente a la línea base	+30.2 %	+41.4 %
Riesgo principal	V2 al 99 % de capacidad	V3 vuelve a las 18:45 (15 min de margen)

☐ **Checklist humano:** factibilidad verificada · holgura en pedidos de alta prioridad · flota real · cierres viales · carga lista para la recarga

ANÁLISIS DE COSTOS Y CUOTAS

¿Cuánto cuesta? (tabla comparativa)

Modelo	Entrada / salida (USD por 1M)	USD por ejecución*
Groq gpt-oss-20b	0.075 / 0.30	**0.009**
Groq gpt-oss-120b	0.15 / 0.60	**0.017**
GPT-5-mini	0.25 / 2.00	0.046
Gemini-2.5-flash	0.30 / 2.50	0.057
Claude Sonnet 4	3.00 / 15.00	0.399
GPT-6 Astra	10.00 / 50.00	1.329

- *Promedio medido: ~47K tokens de entrada + ~17K de salida por ejecución
- Con Groq: menos de US$ 1.20 al mes (66 ejecuciones)
- El límite real no es el costo sino la cuota: A + B consumieron ~128K de los 200K tokens diarios
- Salvedad: hay precios por tramos o introductorios y algunas filas de la tabla están desactualizadas

LECCIONES APRENDIDAS Y LÍMITES

Evaluación crítica

01

Calidad de solución

Los LLM no son optimizadores: planes factibles, pero 30–41 % más caros que una heurística sin LLM.

02

Resiliencia del flujo

Formato roto ocurrió 2 veces: la verificación lo detectó y la replanificación lo corrigió.

03

Detección de anomalías

Errores posibles: cifras mal citadas, formato roto, pedidos omitidos o duplicados → los detecta el motor.

04

Límite de validación

Datos incorrectos pero plausibles no se detectan: garbage in, garbage out.

- **Persona en el circuito:** valida las entradas, corrige si la compuerta falla, aprueba el plan y reasigna en ruta
- **Siguiente versión:** OR-Tools como tool, tráfico real por API, output_pydantic, medir la variabilidad entre ejecuciones

CIERRE

Conclusiones

Lo que demuestra el prototipo

- 4 agentes con roles claros sobre Groq, en un flujo secuencial con replanificación condicional
- Separar razonamiento (LLM) y cálculo (tools) hace que cada cifra de la decisión sea auditable
- Planes factibles y verificados, pero 30–41 % más caros que una heurística: los LLM no optimizan
- Siguiente paso: un optimizador (OR-Tools) como tool y el LLM para explicar y manejar excepciones
- El sistema apoya; la última palabra la tiene el jefe de despacho

¿Preguntas? · Propongan un escenario para probarlo en vivo

